Phone: (+86)18610822831
Email: jl.li@connect.ust.hk

李嘉梁

LinkedIn: 0x0addc001
GitHub: 0x0addc001

教育经历

人工智能 理学硕士 **2025.09 - 2027.01 (预计)**
香港科技大学（*QS33*）工学院

主修课程: 机器学习算法 (机器学习，深度学习, 强化学习), 机器学习应用 (计算机视觉, 自然语言处理, 大语言模型), 机器学习系统 (训练系统, 推理系统), 机器学习伦理

计算机科学与技术 工学学士 **2021.09 - 2025.06**
北京林业大学（*211*）信息学院、人工智能学院

主修课程: 数学 (微积分, 线性代数, 概率论与数理统计, 离散数学), 编程 (C 程序设计, C++ 程序设计, Java 程序设计, Python 程序设计), 电子与计算机工程 (模拟电路, 数字电路) , 计算机科学 (数据结构, 算法设计与分析, 计算机组成原理, 操作系统, 计算机网络, 计算机体系结构, 数据库系统, 编译原理, 计算机网络安全), 软件工程 (软件工程, Web 前端开发, Java Web 后端开发, Android 移动开发), 人工智能 (人工智能)

工作经历

算法工程师（实习） **2026.07 - 2026.10**
小米科技 代码模型后训练

- **数据：**使用 GLM5.3 合成黄金代码需求规格（功能定义、接口契约、关键行为、约束与输出格式）、推理轨迹及 Random/UVM/Cocotb 测试平台；通过代码抽取、长度过滤、规范化、去重、自等价验证和端口抽取构建 SFT、RLVR 业务数据集。
- **训练：**在 Qwen2.5-Coder-7B 上完成 Rejection-sampled SFT（全参与 LoRA）以及以代码执行为 Verifier 的 RLVR + DAPO；对比 Binary/Linear reward，定位奖励增长与下游正确率、域外泛化之间的偏差。
- **评测与交付：**构建业务 Benchmark，使用社区 Benchmark 以 pass@k 评估开源、后训练和商业模型的 Non-Agentic/Agentic RTL 生成；将 GPU 训练与 VCS 仿真解耦，完成 GLM5.3-744B-A40B 的训练适配、数据交付与 smoke test。

算法工程师（实习） **2026.01 - 2026.04**
香港生成式人工智能研发中心 语音模型后训练

- **数据：**使用 Qwen3-ASR 合成普通话-简体、粤语-繁体、英语-英语三语标注，搭建标注审核平台；结合 VAD 语音占比、SNR、说话人独立划分、文本规范化、去重和时长过滤构建 SFT、RL 业务数据集。
- **训练：**在 Qwen3-ASR-1.7B 上完成 Full-Parameter SFT、GRPO 强化学习与超参数调优，针对多语种会议语音优化语言区分与转写稳定性。
- **评测：**构建业务 Benchmark，以 CER 对比开源、后训练和商业 ASR 模型，分析语种混淆、低信噪比和长音频切分等失败类型，并回流到数据筛选与训练配置。

项目经历

VideoAgent：Agent 原生视频生产工作台 **2026.10 - 至今**

- **Agent 编排：**使用 LangGraph 构建受约束的分镜规划器，以 Pydantic 校验 StoryboardPlan，并通过 Agent Hooks 持久化上下文、记忆、规划、校验与回复轨迹；规划层与付费工具隔离。
- **生产系统：**实现可编辑的 Settings/Outline/Script、角色/场景/镜头与版本管理，支持 view/edit 协作、四阶段审批、额度预留和幂等任务；Provider Resolver 覆盖 Pippit/Kling 共 16 个视频模型与 Auto 路由。

- **交付与验证：**通过 Celery + Redis 执行可恢复的异步轮询，使用 FFmpeg 完成字幕、配乐与多画幅成片，并加入 Final Cut 多模态质量评审、限时分享和发布；以 Mock Provider、pytest、Vitest 与 Playwright 验证完整流程。 项目主页

LMPool：面向多 GPU LLM 服务的 KV 感知路由与 NVLink 传输 **2026.04 - 2026.07**

- **系统架构：**将运行时拆分为主进程、全局控制面与逐 GPU 数据面；控制面维护版本化 Block Table、容量、预留和放置元数据，物理 KV Cache 始终由各 GPU 本地持有。
- **路由与传输：**Global Scheduler 综合缺失 Prefill、排队/Decode 工作、回收压力和有效容量选择目标；跨 GPU 传输采用 prepare → execute → publish → finalize 事务，并通过 source hash/generation 校验、目标预留和发布前不可见保证一致性。
- **实验与结果：**在 6×RTX 3090 上对 Qwen3-0.6B/1.7B 重复 5 次；5× 共享前缀路由相比 round robin 提升吞吐 11.8%/21.3%、降低平均 TTFT 18.6%/25.2%。Load skew 完成 3 次后台放置并复制 87 个 block，全部系统、测试与评测代码开源。 项目主页

技术技能

工作语言	中文（母语），英文（托福 92）
编程与工程	Python, C++, C, Java, SQL, Git, Linux, Docker
训练	PyTorch (FSDP), DeepSpeed (ZeRO), Megatron (TP/PP/DP/CP/EP), PEFT (LoRA/QLoRA), verl, SFT, RFT, RLHF, RLVR, DAPO, GRPO, NCCL
推理与服务	vLLM, SGLang, PagedAttention, Prefix Caching, KV Cache, NCCL/NVLink, CUDA
Agent / Harness	LangChain, LangGraph, MCP, Claude Code, Codex, DeepSeek API, FastAPI
应用与交付	Next.js, React, TypeScript, Celery, Redis, PostgreSQL/SQLite, FFmpeg
评测	pass@k, CER, Business Benchmark; VCS, Icarus, UVM, Cocotb; pytest, Vitest, Playwright
运维与发布	GitHub Actions, Docker, canary release, rollback, service health monitoring