Phone: (+86)18610822831
Email: jl.li@connect.ust.hk

李嘉梁

LinkedIn: 0x0addc001
GitHub: 0x0addc001

教育经历

人工智能 理学硕士 **2025.09 - 2027.01 (预计)**
香港科技大学（*QS33*）工学院

主修课程: 机器学习算法 (机器学习，深度学习, 强化学习), 机器学习应用 (计算机视觉, 自然语言处理, 大语言模型), 机器学习系统 (训练系统, 推理系统), 机器学习伦理

计算机科学与技术 工学学士 **2021.09 - 2025.06**
北京林业大学（*211*）信息学院、人工智能学院

主修课程: 数学 (微积分, 线性代数, 概率论与数理统计, 离散数学), 编程 (C 程序设计, C++ 程序设计, Java 程序设计, Python 程序设计), 电子与计算机工程 (模拟电路, 数字电路) , 计算机科学 (数据结构, 算法设计与分析, 计算机组成原理, 操作系统, 计算机网络, 计算机体系结构, 数据库系统, 编译原理, 计算机网络安全), 软件工程 (软件工程, Web 前端开发, Java Web 后端开发, Android 移动开发), 人工智能 (人工智能)

工作经历

算法工程师（实习） **2026.07 - 2026.10**
小米科技 代码模型后训练

- 背景：当前 Coding Agent（特别是 MiMo/开源模型）RTL 代码生成质量不足，使得红区芯片代码研发效率非常受限。
- 需求：希望能够使用已经流片（已验证过）的代码仓库后训练开源模型使之能够更好地理解设计意图来生成编译正确率、功能通过率、可综合性、功耗性能面积（PPA）等更好的 RTL 代码。
- 方案：采取了三条行动路线，首先是数据线，即整理大模型后训练的数据集，确保在大模型训练前数据没有问题。为了检测大模型的数据集在训练中没有问题，先用小模型跑 smoke test，但是小模型有输出长度限制，所以过滤掉所需输出过长的数据作为小模型的数据集。其次是小模型线，即小模型快速验证，确保在大模型训练前代码没有问题、跑出一定效果、找到最佳配置。因此要对小模型训练结果 benchmark 并分析结果，将发现的问题进行定位（是数据的问题还是训练的问题）并修复（针对性和防御性）。最后是大模型线，即大模型正式训练。这需要定制正式训练代码，将训练与仿真解耦（免安装仿真环境与避免 OOM），最后对大模型训练结果 benchmark 并分析结果。
- 结果：在数据线上，制定了数据标准和数据处理流程，将经筛选的 golden code 通过 GLM5.3 正向生成 spec 和反向生成 testbench，验收结果是 Dataset V1 以及优化后的 Dataset V2。在小模型线上，构建了训练（RLVR）与验证（Random/Cocotb/UVM）方案，并从大模型数据集中抽取出所需输出长度 <2k 的数据，在 A100 x 8 下对 Qwen2.5-Coder-7B 进行了训练和评测，并分析训练结果和反哺数据优化。在大模型线上，定制了 GLM5.3-744B-A40B 的训练数据、代码、文档，对数据进行了反复质检与优化，训练代码方面具体是进行了适配、“训练-仿真”解耦与本地 smoke test，并交付训练。

算法工程师（实习） **2026.01 - 2026.04**
香港生成式人工智能研发中心 语音模型后训练

- 背景：当前 ASR 模型对“英语-粤语-普通话”复合识别准确度欠佳，使得多语言的香港政务视频会议转录效果十分有限。

- 需求：希望能够使用真实香港政务会议音频后训练开源模型使之能够更好地区分语言转录来对齐“语音-语言-文字”。
- 方案：采取了两条行动路线，其一是数据线，即整理后训练的数据集，确保在训练前数据没有问题。其二是模型线，即模型训练，先是制定训练方案，然后训练模型，最终对模型训练结果 benchmark 并分析结果，将发现的问题进行定位并修复，反哺数据优化，再迭代训练进行验证。
- 结果：在数据线上，先是制定了数据标准和数据处理流程，然后进行了高效标注平台搭建并协调标注人员使用，最终建立了三语数据集。在模型线上，构建了训练（SFT）方案，在 RTX4090 x 8 下对 Qwen3-ASR-1.7B 进行了训练和评测，并分析训练结果和反哺数据优化。

项目经历

LMPool: 面向多 GPU LLM 服务的 KV Cache 感知路由与 NVLink 传输 **2026.04 - 2026.07**

- 背景：在数据并行 LLM 服务中，每张 GPU 都有独立的 KV Cache。Round robin 会把具有已缓存共享前缀的请求 route 到未必匹配的 GPU，导致重复 prefill，但把所有请求都 route 到 prefix owner 又会形成热点和排队，直接搬运 KV Cache 也并非总是有利，因为 transfer 会占用链路、目标显存和同步开销。
- 需求：实现一个多 GPU LLM serving 系统，优先将请求 route 给已有可用 KV Cache prefix 且负载可接受的 GPU，当 KV Cache placement 与需求或容量不再匹配时，仅在收益覆盖成本时通过 NVLink copy/move 完整 KV block chain，同时需要保证多进程下逻辑 metadata 与物理 block 状态的一致性。
- 方案：将系统拆为主进程、control plane 进程和每 GPU 一个的 data plane 进程。对于 routing，global scheduler 根据 contiguous ready-prefix match、queue token、decode work、effective capacity 和 reclaim pressure 选择路由目标，而不是单纯最大化 hit rate。对于 transfer，实现了 source validation target reservation、packed NCCL P2P transfer、destination publication 和 copy/move finalization 四阶段事务，destination 在 publication 前不可被路由。成本模型按 NVLink pair 和 payload size 使用离线 P95 profile，并用在线残差 EWMA 更新。最后，设计了长共享前缀路由、load skew 和 memory skew 三类受控 workload，并为 block manager、scheduler、control plane、data plane 和 transfer 添加单元与对进程测试。
- 结果：在 RTX 3090 x 6 的五次消融实验中，5x 共享前缀路由在 Qwen3-0.6B/1.7B 上分别带来 11.8%/21.3% 吞吐提升和 18.6%/25.2% 平均 TTFT 降低，未缓存 prefill 约降低 60%。迁移路径完成了逐字节验证，load skew 中执行三次 background placement、复制 87 个 block 并通过 lease 路由 95 个后续请求，memory skew 中 Qwen3-0.6B 安全释放 35 个 source block。全部系统、测试、评测代码已开源，详情请参阅 GitHub: LMPool 。

技术技能

工作语言	中文, 英文 (托福 92)
编程语言	Python, Java, C, C++, SQL
Train 框架	PyTorch (FSDP), DeepSpeed (ZeRO), Megatron (TP/PP/DP/CP/EP), PEFT (LoRA/QLoRA), verl (RLHF/RLVR),
Infer 框架	vLLM (PagedAttention), SGLang (RadixAttention)
Harness 框架	LangChain/LangGraph, Claude Code, Codex